

SQL

Des bases a la preparation d'entretien technique

Requetes, jointures, agregations, fonctions fenetrees,
CTE et index – avec la syntaxe PostgreSQL.

Cours a imprimer – support d'entrainement

Table des matières

1	Introduction	2
2	Types de donnees	2
3	Creer et peupler des tables	3
4	Selectionner des donnees	4
4.1	Astuces de manipulation	4
5	Jointures	5
6	Agregations et regroupement	6
7	Sous-requetes	7
8	CTE – Common Table Expressions	7
9	Fonctions fenetrees (window functions)	8
10	Types de jointure des ensembles	9
11	Index et performance	9
12	Transactions	10
13	Erreurs et pieges frequents	10
14	Fiche recapitulative	10

1. Introduction

SQL (*Structured Query Language*) est le langage utilisé pour interroger et manipuler des données stockées dans une base de données *relationnelle* : des tables composées de lignes et de colonnes, reliées entre elles par des *cles*. Contrairement à un langage comme Python, SQL est *declaratif* : on décrit *quel* résultat on veut, pas *comment* l'obtenir – c'est le *moteur* de la base (le *query planner*) qui choisit la meilleure stratégie d'exécution.

Les exemples de ce cours utilisent la syntaxe **PostgreSQL**. L'essentiel est du SQL standard (norme ANSI) et fonctionne tel quel sur la plupart des moteurs (MySQL, SQL Server, SQLite) ; les différences notables sont signalées dans des encadres.

Les grandes familles de commandes

DDL (*Data Definition Language*) : CREATE, ALTER, DROP – définissent la structure. **DML** (*Data Manipulation Language*) : SELECT, INSERT, UPDATE, DELETE – manipulent les données. **DCL** (*Data Control Language*) : GRANT, REVOKE – gèrent les droits d'accès.

2. Types de données

Chaque colonne d'une table a un *type* fixe, choisi à la création. Le type détermine ce que le SGBD accepte d'y stocker, l'espace occupé sur disque, et les opérations autorisées (on ne peut pas faire de moyenne sur du texte). Bien choisir ses types dès le départ évite des migrations coûteuses plus tard.

Categorie	Types courants (PostgreSQL)
Entiers	SMALLINT (16 bits), INTEGER (32 bits), BIGINT (64 bits). SERIAL/BIGSERIAL : entier auto-incrémenté, pratique pour une clé primaire.
Nombres décimaux	NUMERIC(precision, echelle) : précision exacte, pour de l'argent. REAL, DOUBLE PRECISION : virgule flottante approximative, pour du calcul scientifique.
Texte	TEXT : longueur illimitée. VARCHAR(n) : longueur limitée à n. CHAR(n) : longueur fixe, complète avec des espaces (rarement utile).
Booleen	BOOLEAN : TRUE, FALSE, ou NULL (trois états, pas deux).
Date et heure	DATE (jour seul), TIME (heure seule), TIMESTAMP (date + heure, sans fuseau), TIMESTAMPTZ (date + heure, avec fuseau – recommande des que l'app a des utilisateurs dans plusieurs fuseaux).
Identifiants	UUID : identifiant unique global, utile pour éviter des ID prédictibles ou fusionner des données de plusieurs sources.
Structures	JSON/JSONB : données semi-structurées (JSONB est stocké en binaire, indexable, généralement préféré). ARRAY : tableau d'un type donné (INTEGER[], TEXT[]).

```
CREATE TABLE produits (
  id          BIGSERIAL PRIMARY KEY,
  nom         VARCHAR(120) NOT NULL,
  description TEXT,
  prix        NUMERIC(10, 2) NOT NULL,      -- 10 chiffres, dont 2 après la virgule
  en_stock    BOOLEAN          DEFAULT TRUE,
  tags        TEXT[],           -- tableau de textes
  attributs   JSONB,            -- données libres, indexables
  cree_le     TIMESTAMPTZ      DEFAULT NOW()
```

```
);

-- Conversion explicite entre types avec CAST ou ::
SELECT CAST('42' AS INTEGER);
SELECT '42'::INTEGER;           -- syntaxe raccourcie propre à PostgreSQL
```

NUMERIC vs FLOAT

NUMERIC stocke une valeur *exacte* (aucune erreur d'arrondi) mais est plus lent ; c'est le choix par défaut pour de l'argent. REAL/ DOUBLE PRECISION sont des flottants binaires, plus rapides mais avec des approximations (0.1 + 0.2 peut ne pas donner exactement 0.3) – à réserver aux calculs ou une petite imprecision est acceptable.

Piege courant

VARCHAR(n) sans n et TEXT sont strictement équivalents en PostgreSQL (aucune différence de performance) : la limite de longueur n'apporte qu'une validation, pas un gain de vitesse. Ne pas confondre avec MySQL, où VARCHAR et TEXT sont stockés différemment.

3. Créer et peupler des tables

Une table est définie par ses colonnes, chacune avec un *type* et d'éventuelles *contraintes*. Les contraintes empêchent les données invalides d'entrer dans la base – c'est la première ligne de défense de l'intégrité des données, avant même le code applicatif.

```
CREATE TABLE clients (
    id          SERIAL PRIMARY KEY,           -- entier auto-incremente
    nom         TEXT NOT NULL,
    email       TEXT UNIQUE NOT NULL,
    age         INTEGER CHECK (age >= 0),
    cree_le     TIMESTAMP DEFAULT NOW()
);

CREATE TABLE commandes (
    id          SERIAL PRIMARY KEY,
    client_id   INTEGER NOT NULL REFERENCES clients(id), -- cle étrangere
    montant     NUMERIC(10, 2) NOT NULL,
    statut      TEXT DEFAULT 'en_attente'
);

INSERT INTO clients (nom, email, age)
VALUES ('Alice', 'alice@mail.com', 30),
       ('Bob', 'bob@mail.com', 25);

UPDATE clients SET age = 31 WHERE nom = 'Alice';

DELETE FROM clients WHERE email = 'bob@mail.com';
```

Piege courant

DELETE FROM table sans clause WHERE supprime **toutes** les lignes. UPDATE table SET ... sans WHERE modifie **toutes** les lignes. Toujours vérifier la clause WHERE avant d'exécuter, surtout en production – idéalement, tester d'abord avec un SELECT utilisant la même condition.

4. Sélectionner des données

SELECT est la commande la plus utilisée : elle extrait des lignes d'une ou plusieurs tables. L'ordre *logique* d'exécution d'une requête n'est pas l'ordre dans lequel on l'écrit – comprendre cet ordre évite beaucoup d'erreurs (par exemple, pourquoi un alias défini dans **SELECT** n'est pas utilisable dans **WHERE**).

Ordre logique d'exécution

FROM → JOIN → WHERE → GROUP BY → HAVING → SELECT → DISTINCT → ORDER BY → LIMIT.
WHERE filtre les lignes *avant* regroupement ; **HAVING** filtre les groupes *après*.

```
SELECT nom, age
FROM clients
WHERE age >= 18 AND nom ILIKE 'a%'      -- ILIKE = LIKE insensible à la casse
ORDER BY age DESC
LIMIT 10;

-- Colonnes calculées et alias
SELECT nom, age, age >= 18 AS majeur
FROM clients;

-- Valeurs distinctes
SELECT DISTINCT statut FROM commandes;

-- Tester une valeur NULL : jamais avec = ou !=
SELECT * FROM clients WHERE email IS NOT NULL;

-- Plage de valeurs et liste de valeurs
SELECT * FROM clients WHERE age BETWEEN 18 AND 65;
SELECT * FROM commandes WHERE statut IN ('en_attente', 'expediee');
```

Piège courant

NULL représente une valeur *inconnue*, pas zéro ni chaîne vide. `colonne = NULL` ne renvoie jamais **TRUE** (même si la colonne est vraiment **NULL**) : il faut `IS NULL` ou `IS NOT NULL`.

4.1 Astuces de manipulation

Au-delà du simple filtrage, quelques fonctions et opérateurs reviennent sans cesse pour *extraire*, *nettoyer* ou *transformer* une colonne directement dans la requête – sans avoir à rapatrier les données brutes pour les retravailler côté application.

```
-- Debut / fin d'une chaîne : LEFT et RIGHT prennent un nombre de caractères
SELECT LEFT(nom, 3)   AS debut,      -- 3 premiers caractères
       RIGHT(nom, 3)  AS fin        -- 3 derniers caractères
FROM clients;

-- SUBSTRING : extraire depuis une position, sur une longueur donnée
SELECT SUBSTRING(email FROM 1 FOR 5) AS debut_email,
       SUBSTRING(email FROM POSITION('@' IN email) + 1) AS domaine
FROM clients;

-- LENGTH : longueur d'une chaîne (utile combine à LEFT/RIGHT pour du dynamique)
SELECT nom, LENGTH(nom) AS longueur FROM clients;

-- Nettoyage : équivalents SQL de strip/lstrip/rstrip en Python
SELECT TRIM(nom), LTRIM(nom), RTRIM(nom) FROM clients;
```

```

SELECT TRIM(BOTH '#' FROM '##titre##');           -- 'titre'

-- Casse et concatenation
SELECT UPPER(nom), LOWER(email) FROM clients;
SELECT nom || ' <' || email || '>' AS contact FROM clients; -- || = concatenation
SELECT CONCAT(nom, ' <', email, '>') AS contact FROM clients; -- equivalent, gere les
NULL

-- Remplacement
SELECT REPLACE(email, '@mail.com', '@nouveau.com') FROM clients;

-- COALESCE : premiere valeur non-NULL dans une liste -- LA methode pour
-- gerer les valeurs manquantes sans passer par un CASE WHEN
SELECT nom, COALESCE(tel, 'non renseigné') AS tel FROM clients;

-- NULLIF : renvoie NULL si les deux valeurs sont egales (utile pour eviter
-- une division par zero sans passer par un CASE WHEN)
SELECT total / NULLIF(quantite, 0) AS prix_unitaire FROM commandes;

-- CASE WHEN : la seule structure conditionnelle de SQL, comme un if/elif/else
SELECT nom, age,
       CASE
         WHEN age < 18 THEN 'mineur'
         WHEN age < 65 THEN 'adulte'
         ELSE 'senior'
       END AS categorie
FROM clients;

```

Alignement des positions

En SQL, les positions de chaîne commencent à 1 (pas 0 comme en Python). `LEFT(s, n)` et `RIGHT(s, n)` avec un `n` négatif retirent `n` caractères depuis l'autre bout (`LEFT('bonjour', -2)` donne 'bonj') – pratique mais facile à oublier.

Piège courant

`COALESCE` et `CASE WHEN` s'arrêtent à la première condition vraie / première valeur non-NULL : l'ordre des arguments compte. Utiliser `||` pour concatener avec une valeur NULL propage le NULL à toute la chaîne résultante ('a' || NULL donne NULL, pas 'a'); `CONCAT` n'a pas ce problème, il traite NULL comme une chaîne vide.

5. Jointures

Une jointure combine les lignes de deux tables selon une condition de correspondance (généralement une clé étrangère). C'est le mécanisme qui justifie de *normaliser* les données (les répartir dans plusieurs tables sans duplication) plutôt que de tout stocker dans une seule table plate.

```

-- INNER JOIN : seulement les lignes qui correspondent des deux cotes
SELECT c.nom, o.montant
FROM clients c
INNER JOIN commandes o ON o.client_id = c.id;

-- LEFT JOIN : toutes les lignes de gauche, meme sans correspondance a droite
-- (colonnes de droite a NULL si pas de commande)
SELECT c.nom, o.montant
FROM clients c
LEFT JOIN commandes o ON o.client_id = c.id;

```

```
-- Clients SANS aucune commande (anti-jointure classique)
SELECT c.nom
FROM clients c
LEFT JOIN commandes o ON o.client_id = c.id
WHERE o.id IS NULL;

-- FULL OUTER JOIN : union des deux cotes, correspondance ou non
SELECT c.nom, o.montant
FROM clients c
FULL OUTER JOIN commandes o ON o.client_id = c.id;

-- Jointure d'une table sur elle-meme (self-join) : ex. trouver les paires
-- d'employes qui partagent le meme manager
SELECT e1.nom AS employe, e2.nom AS collegue
FROM employes e1
JOIN employes e2 ON e1.manager_id = e2.manager_id AND e1.id < e2.id;
```

Quelle jointure choisir ?

INNER JOIN : uniquement les correspondances (le plus courant). LEFT JOIN : tout de la table de gauche, complete par NULL si pas de correspondance – utile pour « trouver ce qui manque ». FULL OUTER JOIN : rare, sert à comparer deux ensembles en gardant tout des deux cotes.

Piege courant

Filtrer sur la table de droite d'un LEFT JOIN dans le WHERE (au lieu du ON) transforme silencieusement le LEFT JOIN en INNER JOIN : WHERE o.statut = 'payee' elimine les clients sans commande alors qu'on voulait les garder. La condition sur la table jointe doit rester dans le ON si on veut conserver les lignes sans correspondance.

6. Agregations et regroupement

Les fonctions d'agregation (COUNT, SUM, AVG, MIN, MAX) resument plusieurs lignes en une seule valeur. GROUP BY les applique *par groupe* plutot que sur toute la table : chaque valeur distincte des colonnes groupees devient une ligne de resultat. Toute colonne du SELECT qui n'est pas agregee doit apparaitre dans le GROUP BY.

```
-- Nombre et montant total de commandes par client
SELECT client_id, COUNT(*) AS nb_commandes, SUM(montant) AS total
FROM commandes
GROUP BY client_id;

-- HAVING filtre les groupes (apres agregation) ; WHERE filtre les lignes (avant)
SELECT client_id, SUM(montant) AS total
FROM commandes
WHERE statut = 'payee' -- filtre les lignes avant regroupement
GROUP BY client_id
HAVING SUM(montant) > 100; -- filtre les groupes apres regroupement

-- COUNT(*) compte les lignes ; COUNT(colonne) ignore les NULL de cette colonne
SELECT COUNT(*) AS total_lignes, COUNT(email) AS emails_renseignes
FROM clients;
```

Piège courant

WHERE ne peut pas utiliser un alias défini dans **SELECT**, ni filtrer sur le résultat d'une agrégation (**WHERE COUNT(*) > 1** est invalide) : l'agrégation n'existe pas encore à ce stade de l'exécution logique. C'est justement le rôle de **HAVING**.

7. Sous-requetes

Une sous-requete est une requete imbriquée dans une autre. Elle peut apparaître dans le **WHERE** (filtrer), dans le **FROM** (comme une table temporaire), ou dans le **SELECT** (une valeur calculée par ligne).

```
-- Sous-requete scalaire : clients dont l'age depasse la moyenne
SELECT nom, age
FROM clients
WHERE age > (SELECT AVG(age) FROM clients);

-- Sous-requete avec IN : clients ayant au moins une commande payee
SELECT nom FROM clients
WHERE id IN (SELECT client_id FROM commandes WHERE statut = 'payee');

-- EXISTS : souvent plus rapide que IN sur de gros volumes,
-- s'arrete des la premiere ligne trouvee
SELECT nom FROM clients c
WHERE EXISTS (
    SELECT 1 FROM commandes o
    WHERE o.client_id = c.id AND o.statut = 'payee'
);

-- Sous-requete correelee dans le SELECT : montant total par client, en ligne
SELECT nom,
    (SELECT SUM(montant) FROM commandes o WHERE o.client_id = c.id) AS total
FROM clients c;
```

8. CTE – Common Table Expressions

Une CTE (clause **WITH**) nomme une sous-requete pour la reutiliser et rendre une requete complexe lisible, comme on decoupe un long calcul en variables intermediaires. Une CTE *recursive* permet de parcourir des structures hierarchiques (arbre, graphe) que SQL ne sait pas traverser nativement autrement.

```
-- CTE simple : lisibilite d'une requete en plusieurs etapes
WITH ventes_par_client AS (
    SELECT client_id, SUM(montant) AS total
    FROM commandes
    GROUP BY client_id
)
SELECT c.nom, v.total
FROM clients c
JOIN ventes_par_client v ON v.client_id = c.id
WHERE v.total > 500;

-- CTE recursive : remonter toute la hierarchie d'un employe (ex. organigramme)
WITH RECURSIVE hierarchie AS (
    -- cas de base : l'employe de depart
    SELECT id, nom, manager_id, 1 AS niveau
```



```

FROM employes
WHERE id = 42

UNION ALL

-- cas recursif : le manager du precedent, niveau par niveau
SELECT e.id, e.nom, e.manager_id, h.niveau + 1
FROM employes e
JOIN hierarchie h ON e.id = h.manager_id
)
SELECT * FROM hierarchie;

```

Quand utiliser une CTE

Des qu'une sous-requete est reutilisee plusieurs fois, ou que la requete devient difficile a lire d'un seul bloc. La CTE recursive est le seul moyen standard de parcourir un nombre variable de niveaux (organigramme, categories imbriquees, graphe de dependances).

9. Fonctions fenetrees (window functions)

Une fonction fenetree calcule une valeur *a travers un ensemble de lignes liees a la ligne courante* (la *fenetre*), **sans** regrouper les lignes comme le fait **GROUP BY** : chaque ligne du resultat reste individuelle. C'est l'outil pour repondre a des questions comme « le rang de chaque commande », « le cumul depuis le debut », ou « comparer une ligne a la precedente ».

```

-- Classement des commandes par montant, au sein de chaque client
SELECT client_id, montant,
       RANK() OVER (PARTITION BY client_id ORDER BY montant DESC) AS rang
FROM commandes;

-- Cumul progressif (running total) par client, trie par date
SELECT client_id, montant,
       SUM(montant) OVER (PARTITION BY client_id ORDER BY id) AS cumul
FROM commandes;

-- Comparer chaque ligne a la precedente / suivante
SELECT client_id, montant,
       LAG(montant) OVER (PARTITION BY client_id ORDER BY id) AS montant_precedent,
       LEAD(montant) OVER (PARTITION BY client_id ORDER BY id) AS montant_suivant
FROM commandes;

-- ROW_NUMBER : numeroter les lignes -- utile pour dedupliquer
SELECT *
FROM (
  SELECT *, ROW_NUMBER() OVER (PARTITION BY email ORDER BY id) AS rn
  FROM clients
) t
WHERE rn = 1;    -- garde seulement la premiere ligne de chaque email en double

```

RANK vs DENSE_RANK vs ROW_NUMBER

Pour des valeurs ex aequo : **ROW_NUMBER** attribue toujours un numero unique (1, 2, 3...) sans egard aux egalites. **RANK** laisse un « trou » apres une egalite (1, 2, 2, 4...). **DENSE_RANK** n'en laisse pas (1, 2, 2, 3...).

10. Types de jointure des ensembles

UNION, INTERSECT et EXCEPT combinent les *resultats* de deux requetes ayant le meme nombre de colonnes et des types compatibles – a ne pas confondre avec les jointures, qui combinent des *colonnes*.

```
-- UNION : combine et supprime les doublons ; UNION ALL les garde (plus rapide)
SELECT nom FROM clients_actifs
UNION
SELECT nom FROM clients_archives;

-- INTERSECT : lignes presentes dans les deux requetes
SELECT email FROM clients
INTERSECT
SELECT email FROM newsletter_abonnes;

-- EXCEPT : lignes de la premiere requete absentes de la seconde
SELECT email FROM clients
EXCEPT
SELECT email FROM newsletter_abonnes;
```

11. Index et performance

Un index est une structure auxiliaire (le plus souvent un arbre B) qui accelere la recherche sur une colonne, au prix d'un espace disque supplementaire et d'un cout a chaque ecriture (l'index doit etre mis a jour). Sans index, chercher une valeur oblige a parcourir la table entiere (*sequential scan*).

```
-- Index simple sur une colonne souvent filtree
CREATE INDEX idx_commandes_client_id ON commandes(client_id);

-- Index composite : utile si les requetes filtrent sur les deux colonnes
-- ensemble (l'ordre des colonnes compte : la premiere doit etre la plus
-- selective ou la plus souvent utilisee seule)
CREATE INDEX idx_commandes_client_statut ON commandes(client_id, statut);

-- Verifier ce que le moteur fait reellement : lit-il l'index ou la table entiere ?
EXPLAIN ANALYZE
SELECT * FROM commandes WHERE client_id = 42;
```

Quand indexer

Indexer les colonnes utilisees dans WHERE, JOIN ... ON et ORDER BY sur de grandes tables. Les cles primaires et (souvent) les cles etrangeres sont deja indexees automatiquement par le SGBD (a verifier : sur PostgreSQL, une cle etrangere n'est **pas** indexee automatiquement, contrairement a la cle primaire).

Piege courant

Un index existe mais n'est pas utilise si la requete applique une fonction sur la colonne indexee (WHERE LOWER(email) = ... n'utilise pas un index simple sur email) ou si le filtre porte sur trop peu de lignes distinctes (un index sur une colonne booleenne est rarement utile). Trop d'index ralentissent aussi les ecritures (INSERT/UPDATE) : ce n'est pas gratuit, il faut indexer avec intention.

12. Transactions

Une transaction regroupe plusieurs opérations en une seule unité *atomique* : soit toutes réussissent (**COMMIT**), soit aucune n'est appliquée (**ROLLBACK**). Indispensable dès qu'une opération logique touche plusieurs tables – par exemple, debiter un compte et en créditer un autre ne doit jamais s'arrêter à mi-chemin.

```
BEGIN;

UPDATE comptes SET solde = solde - 100 WHERE id = 1;
UPDATE comptes SET solde = solde + 100 WHERE id = 2;

-- Si tout s'est bien passé :
COMMIT;

-- Si une vérification échoue (ex. solde négatif) :
-- ROLLBACK;
```

Propriétés ACID

Atomicité (tout ou rien) – **C**ohérence (les contraintes restent respectées) – **I**solation (les transactions concurrentes ne se perturbent pas) – **D**urabilité (une fois validée, une transaction survit même à une panne).

13. Erreurs et pièges fréquents

Piège	Explication
= NULL au lieu de IS NULL	Ne renvoie jamais TRUE ; utiliser IS NULL / IS NOT NULL.
WHERE sur une table jointe en LEFT JOIN	Transforme silencieusement le LEFT JOIN en INNER JOIN ; filtrer dans le ON.
Colonne non agréée absente du GROUP BY	Erreur (Postgres) ou valeur arbitraire (MySQL en mode permissif).
HAVING vs WHERE	WHERE filtre avant regroupement, HAVING après.
DELETE/UPDATE sans WHERE	Affecte toutes les lignes de la table.
SELECT * en production	Casse si les colonnes changent ; ramène des données inutiles ; nommer les colonnes explicitement.
Comparer des types incompatibles	'10' = 10 peut fonctionner par conversion implicite mais dégrade les performances (l'index n'est plus utilisable) et masque des bugs.
Oublier les fuseaux horaires	Préférer TIMESTAMPTZ à TIMESTAMP dès que l'application a des utilisateurs dans plusieurs fuseaux.

14. Fiche récapitulative

Concept	A retenir
Ordre logique	FROM > JOIN > WHERE > GROUP BY > HAVING > SELECT > ORDER BY > LIMIT.
INNER vs LEFT JOIN	INNER = correspondances uniquement ; LEFT = tout de la table de gauche + NULL.
WHERE vs HAVING	Avant regroupement vs apres regroupement.
IN vs EXISTS	EXISTS s'arrete des la premiere correspondance, souvent plus rapide sur de gros volumes.
CTE (WITH)	Nomme une sous-requete ; WITH RECURSIVE pour les hierarchies.
Fonctions fenetrees	OVER (PARTITION BY ... ORDER BY ...) : calcule sans regrouper les lignes.
Index	Accelere la lecture, ralentit l'ecriture ; verifier avec EXPLAIN ANALYZE.
Transaction	BEGIN / COMMIT / ROLLBACK ; proprietes ACID.
NULL	Valeur inconnue ; toujours IS NULL, jamais = NULL.

Methode pour ecrire une requete complexe

1. Identifier les tables necessaires et comment elles se reliant (cles).
2. Ecrire d'abord le FROM/JOIN, verifier avec SELECT * que les lignes obtenues sont les bonnes.
3. Ajouter les filtres (WHERE), puis le regroupement (GROUP BY/HAVING) si necessaire.
4. Ne selectionner les colonnes finales et trier (ORDER BY) qu'en dernier.
5. Sur une grosse table, verifier le plan d'execution (EXPLAIN ANALYZE) avant de considerer la requete terminee.